دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

گزارش پروژه اول درس مبانی هوش محاسباتی

پیاده‌سازی شبکه عصبی تمام متصل دیتاست MNIST

مهرآذین مرزوق – ۴۰۰۳۶۱۳۰۵۵

فهرست

انتخاب تعداد لایه‌ها

تعداد مناسب لایه برای یک پرسپترون چند لایه به چندین فاکتور وابسته است:

پیچیدگی دیتاست MNIST: این دیتاست تقریبا دیتاست ساده‌ای است. اما پرسپترون چندلایه می‌تواند الگوهای پیچیده‌تری را یاد بگیرد. بنابراین اگر تعداد لایه‌ها اندکی بیشتر شود، به سرعت overfitting رخ می‌دهد.

معمولا برای دیتاست MNIST از ۲ یا ۳ لایه استفاده می‌شود؛ اما باید توجه داشت که در صورتی که از ۳ لایه استفاده کنیم، باید بیشتر مراقب بیش‌برازش باشیم.

دو لایه: لایه اول ویژگی‌ها را استخراج می‌کند و لایه دوم، ویژگی‌ها را برای classification ترکیب می‌کند.

```
# Add two fully-connected layers to the network
model.add(tf.keras.layers.Dense(512, activation='relu',
input_shape=(28 * 28,)))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
```

```
Test Accuracy: 0.9534000158309937
Test Loss: 0.16711154580116272
Validation Accuracy: 0.9519000053405762
Validation Loss: 0.17070327699184418
```

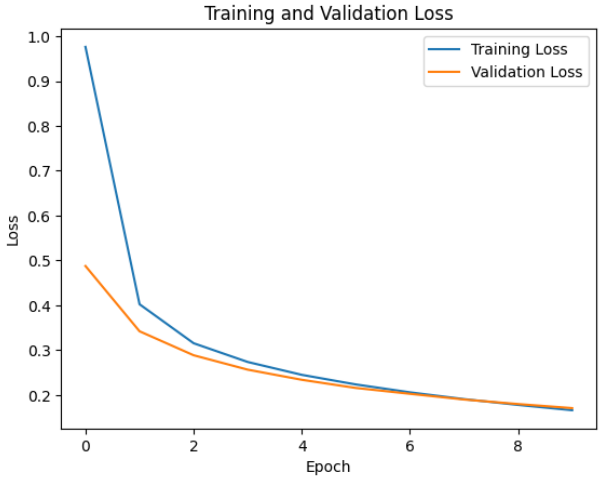

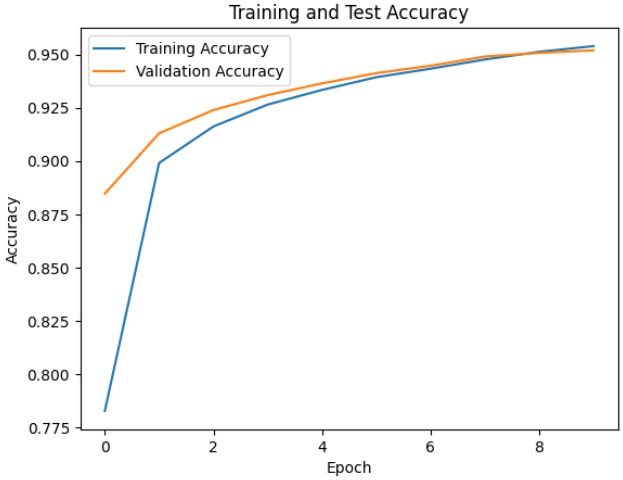

سه لایه:

```
# Add three fully-connected layers to the network.
model.add(tf.keras.layers.Flatten(input_shape=(28 * 28,)))
model.add(tf.keras.layers.Dense(32, activation='relu'))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
```

```
Test Accuracy: 0.9079999923706055
Test Loss: 0.3306991159915924
Validation Accuracy: 0.9064000248908997
Validation Loss: 0.340914785861969
```

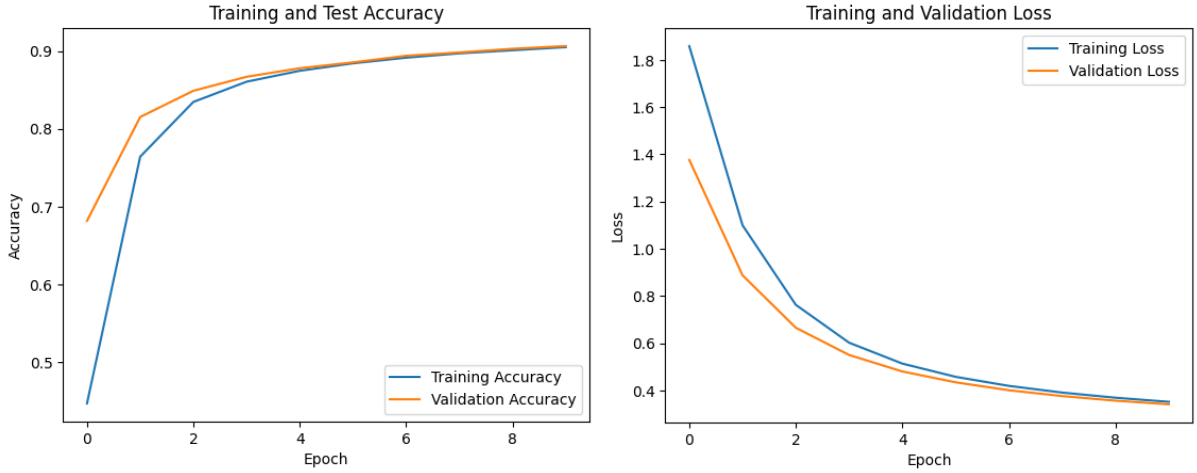

در اینجا مشاهده می‌شود که با ۳ لایه، دقت پایین می‌آید. به علت این‌که این دیتاست، دیتاست ساده‌ای است و استفاده از ۳ لایه باعث افزایش پیچیدگی هم در پیاده‌سازی و هم در اجرا می‌شود، تصمیم بر این می‌شود که از ۲ لایه استفاده کنیم.

انتخاب تعداد نورون‌های هر لایه

در رابطه با دیتاست MNIST در صورتی که از ۲ لایه استفاده شود، معمولا از ۵۱۲ نورون در لایه اول استفاده می‌شود. ما این عدد را در نظر میگیرم و با بالا و پایین کردن این عدد، به بررسی نتایج می‌پردازیم.
معیار ما برای مناسب بودن تعداد نورون‌های لایه اول، validation accuracy و train accuracy را مقایسه می‌کنیم. اعداد بالای ۰.۹۵ که در این دو به هم نزدیک باشند، به معنی این است که مدل به خوبی داده را آموخته است و از بیش برازش جلوگیری می‌کند. همچنین بررسی می‌کنیم که test accuracy در حال افزایش و test loss درحال کاهش باشد.

:۵۱۲

```
Test Accuracy: 0.953499972820282
Test Loss: 0.16269086301326752
Validation Accuracy: 0.9532999992370605
Validation Loss: 0.16897334158420563
Train Accuracy: 0.957099974155426
Train Loss: 0.1573188155889511
```

:۲۵۶

```
Test Accuracy: 0.9430999755859375
Test Loss: 0.2028328776359558
Validation Accuracy: 0.9447000026702881
Validation Loss: 0.20519550144672394
Train Accuracy: 0.9460399746894836
Train Loss: 0.1990952342748642
```

در اینجا test accuracy نسبت به قبل افزایش پیدا کرده، validation accuracy و test accuracy از ۰.۹۵ کمتر و نسبت به قبل کاهش پیدا کرده‌اند.

این نشان می‌دهد که تعداد نورون کمتر از ۵۱۲ باعث underfitting در مدل می‌شود.

:۱۰۲۴

```
Test Accuracy: 0.9624999761581421
Test Loss: 0.12894481420516968
Validation Accuracy: 0.9629999995231628
Validation Loss: 0.13496488332748413
Train Accuracy: 0.9688799977302551
Train Loss: 0.11788497120141983
```

:۲۰۴۸

```
Test Accuracy: 0.9677000045776367
Test Loss: 0.10813374072313309
```

```
Validation Accuracy: 0.9692999720573425
Validation Loss: 0.11196314543485641
Train Accuracy: 0.9769799709320068
Train Loss: 0.08993370831012726
```

این تعداد نورون پیچیدگی زمانی زیادی دارد.

۴۰۹۶:

```
Test Accuracy: 0.9746999740600586
Test Loss: 0.08622105419635773
Validation Accuracy: 0.973800003528595
Validation Loss: 0.09152911603450775
Train Accuracy: 0.9848999977111816
Train Loss: 0.0626753717660904
```

این تعداد نورون با اینکه دقت را بالا می‌برد، اما پیچیدگی زیادی دارد و اجرای آن از نظر زمانی و سخت‌افزاری به‌صرفه نیست.

در نهایت تعداد ۱۰۲۴ نورون برای لایه اول انتخاب می‌شود.

در لایه دوم، به علت اینکه ۱۰ تا کلاس خواهیم داشت، از ۱۰ نورون استفاده می‌کنیم.

انتخاب الگوریتم بهینه‌سازی

Adam: این الگوریتم یک الگوریتم کاهش گرادیان تصادفی است؛ از نظر محاسباتی بهینه است، به حافظه کمی نیاز دارد، نسبت به مقیاس مجدد مورب گرادیان‌ها ثابت است و برای مسائلی که تعداد زیادی دیتا و پارامتر وجود دارد مناسب است. کد زیر، کد پیشفرض کتابخانه keras برای الگوریتم adam می‌باشد. برای تست کردن، از مقادیر پیشفرض استفاده می‌کنیم.

```
) keras.optimizers.Adam(
    learning_rate=0.001,
    beta_1=0.9,
    beta_2=0.999,
    epsilon=1e-07,
    amsgrad=False,
    weight_decay=None,
    clipnorm=None,
    clipvalue=None,
    global_clipnorm=None,
    use_ema=False,
    ema_momentum=0.99,
    ema_overwrite_frequency=None,
    loss_scale_factor=None,
    gradient_accumulation_steps=None,
    name="adam",
    **kwargs
)
```

```
# Compile the model.
model.compile(optimizer='adam', loss='categorical_crossentropy',
metrics=['accuracy'])
```

```
Test Accuracy: 0.9803000092506409
Test Loss: 0.0634884163737297
Validation Accuracy: 0.9800999760627747
Validation Loss: 0.06448717415332794
Train Accuracy: 0.9991199970245361
Train Loss: 0.008130251429975033
```

RMSProp : این الگوریتم از نظر محاسباتی، به ویژه زمانی که با مجموعه داده های بزرگ سروکار داریم، بهینه است. با استفاده از یک مثال واحد یا یک دسته کوچک، هزینه محاسباتی در هر تکرار در مقایسه با روش‌های سنتی گرادیان نزولی که نیاز به پردازش کل مجموعه داده دارند، به میزان قابل توجهی کاهش می‌یابد. کد زیر، کد پیشفرض کتابخانه keras برای الگوریتم RMSProp می‌باشد. برای تست کردن، از مقادیر پیشفرض استفاده می‌کنیم.

```
keras.optimizers.RMSprop(
```

```
    learning_rate=0.001,
    rho=0.9,
    momentum=0.0,
    epsilon=1e-07,
    centered=False,
    weight_decay=None,
    clipnorm=None,
    clipvalue=None,
    global_clipnorm=None,
    use_ema=False,
    ema_momentum=0.99,
    ema_overwrite_frequency=None,
    loss_scale_factor=None,
    gradient_accumulation_steps=None,
    name="rmsprop",
    **kwargs
```

```
# Compile the model.
model.compile(optimizer='rmsprop', loss='categorical_crossentropy',
metrics=['accuracy'])
```

```
Test Accuracy: 0.9819999933242798
Test Loss: 0.06130603700876236
Validation Accuracy: 0.9810000061988831
Validation Loss: 0.06498846411705017
Train Accuracy: 0.9985600113868713
Train Loss: 0.008354941383004189
```

مقایسه این دو مدل:

adam

- مزایا:
  - اغلب سریعتر از RMSprop همگرا می شود
  - دارای نرخ یادگیری تطبیقی با مومنتوم است که با مسائل گرادیان های در حال ناپدید شدن/منفجر شدن مقابله می کند
  - در بسیاری از چارچوب های یادگیری عمیق به عنوان بهینه ساز پیش فرض در نظر گرفته می شود
- معایب:
  - ممکن است نسبت به RMSprop به محاسبات کمی بیشتر نیاز داشته باشد

RMSprop

- مزایا:
  - گرادیان های پراکنده را که در شبکه های عصبی رایج هستند به طور موثر مدیریت می کند

- به طور کلی از نظر محاسباتی کم هزینه تر از Adam است
- معایب:
  - ممکن است در برخی موارد کندتر از Adam همگرا شود
  - از تصحیح سوگیری Adam که می تواند در مراحل بعدی آموزش مفید باشد، بی بهره است

با توجه به سادگی مجموعه داده MNIST و یک MLP دو لایه، هر دو بهینه ساز ممکن است به نتایج خوبی دست یابند. با این حال، adam اغلب به دلیل موارد زیر به عنوان پیش فرض توصیه می شود:

- همگرایی سریعتر (احتمالی)
- یادگیری تطبیقی با مومنتوم
- اثربخشی به عنوان یک بهینه ساز چند منظوره

انتخاب نرخ یادگیری

نرخ یادگیری میزان قدم‌های مدل را که برای به‌دست آوردن وزن سیناپس‌ها استفاده می‌شود، مشخص می‌کند.

نرخ یادگیری به‌طور پیش‌فرض در الگوریتم بهینه‌ساز مورد نظر انتخاب شده است. نرخ یادگیری پیش‌فرض در الگوریتم `adam` همانطور که در بخش قبل مشاهده شد، برابر با ۰.۰۰۱ است.

نرخ یادگیری کوچک (۰.۰۰۰۱) پایداری بیشتری دارد و همچنین شانس بیشتری برای پیدا کردن `global minimum` دارد. اما یادگیری کندتر است (و گاهی ممکن است که در `shallow minima` گیر کند).

نرخ یادگیری بزرگ یادگیری سریعتری دارد اما ناپایدار است و ممکن است در `local minimum` گیر کند.

در این پروژه ابتدا از ۰.۰۰۰۱ شروع می‌کنیم و نتایج مربوط به `loss` را بررسی می‌کنیم. اگر `validation loss` افزایش پیدا کند، نرخ یادگیری احتمالا بزرگ است و اگر ثابت بماند، بسیار کوچک است.

:۰.۰۰۰۱

```
Test Accuracy: 0.9623000025749207
Test Loss: 0.13262595236301422
Validation Accuracy: 0.9620000123977661
Validation Loss: 0.1367652416229248
Train Accuracy: 0.968280017375946
Train Loss: 0.12076471000909805
```

:۰.۰۰۱

```
Test Accuracy: 0.9825000166893005
Test Loss: 0.061019714921712875
Validation Accuracy: 0.9812999963760376
Validation Loss: 0.05988801270723343
Train Accuracy: 0.9994000196456909
Train Loss: 0.006334839388728142
```

:۰.۰۱

```
Test Accuracy: 0.9707000255584717
Test Loss: 0.16833384335041046
Validation Accuracy: 0.9695000052452087
Validation Loss: 0.17394115030765533
Train Accuracy: 0.9880399703979492
Train Loss: 0.04146776348352432
```

طبق توضیحات قبل، بهترین عدد ۰.۰۰۱ است که پیش‌فرض `adam` است.

```
# # Compile the model.
```

```
optimizer = tf.keras.optimizers.Adam(learning_rate=0.001)
model.compile(optimizer=optimizer, loss='categorical_crossentropy',
metrics=['accuracy'])
```

تاثیر overfitting و underfitting

Overfitting

زمانی رخ می دهد که مدل شما جزئیات و نویز خاصی را که در داده های آموزشی وجود دارد به خاطر می آورد. به علاوه اینکه الگوهای زمینه‌ای را که به نمونه های دیده نشده تعمیم می یابد، یاد بگیرد.

- علائم
  - دقت آموزش بالا اما دقت بسیار پایین در داده‌های validation یا test است.
- چگونه با MNIST اتفاق می افتد:
  - استفاده از یک مدل پیچیده با پارامترهای بسیار زیاد برای اندازه مجموعه داده MNIST می تواند منجر به overfittingشود.
  - فقدان تکنیک های افزایش داده (به عنوان مثال، چرخش های تصادفی، تزریق نویز) می تواند توانایی مدل را برای تعمیم به تغییراتی که در مجموعه آموزشی وجود ندارد محدود کند.

Underfitting

زمانی رخ می دهد که مدل شما بسیار ساده باشد و از ظرفیت یادگیری پیچیدگی های موجود در داده ها برخوردار نباشد.

- علائم
  - دقت پایین در مجموعه های train و test/validation
  - مدل ممکن است حتی در تمایز بین اشکال اولیه رقم نیز با مشکل مواجه شود.
- چگونه با MNIST اتفاق می افتد:
  - استفاده از مدلی با لایه های بسیار کم یا نورون های بسیار کم می تواند توانایی آن را برای گرفتن ویژگی های لازم برای طبقه بندی دقیق رقم محدود کند.
  - آموزش برای تعداد غیربهینه از epochs ممکن است مانع از یادگیری کامل الگوهای موجود در داده ها توسط مدل شود.

استراتژی هایی برای اجتناب از overfitting و underfitting

- مجموعه validation : یک مجموعه اعتبارسنجی نگه داشته شده به شما امکان می دهد عملکرد مدل را روی داده های دیده نشده در طول آموزش کنترل کنید. این به شناسایی زودهنگام overfitting کمک می کند.
- توقف زودهنگام: هنگامی که افت اعتبارسنجی ثابت شد، آموزش را متوقف کنید تا از به خاطر سپردن نویز در داده های آموزشی توسط مدل جلوگیری شود.
- انتخاب مدل: با معماری های مدل مختلف (تعداد لایه ها، نورون ها) و پارامترهای آموزشی آزمایش کنید.

شرایط توقف

در چنین پروژه‌ای، شرایط توقف به ۴ نوع می‌توانند باشند.

نوع اول: توقف زودهنگام

در این روش، با بررسی validation loss و validation accuracy ، اگر تغییرات این دو از epoch ای به بعد ناچیز یا منفی بود، یادگیری را متوقف می‌کنیم که وارد فاز overfitting نشویم

نوع دوم: رسیدن به یک validation accuracy مشخص

در این روش، اگر زودتر از تعداد epoch مورد نظر به accuracy مورد انتظار رسیدیم، یادگیری را متوقف می‌کنیم که وارد فاز overfittng نشویم.

نوع سوم: بیشترین epoch

در این روش، عددی را برای تعداد epoch ارائه می‌دهیم که نه underfitting و نه overfitting داشته باشیم.

نوع چهارم: کاهش نرخ یادگیری

در این روش، ابتدا مدل گام‌های بزرگی برای یادگیری برمی‌دارد و با گذشت زمان، این گام‌ها را کوچک‌تر می‌کند زیرا که احتمالا در آن زمان، به global minima نزدیک‌تر شده است و باید با احتیاط بیشتری حرکت کند. این کار باعث می‌شود که نسبت به نرخ یادگیری ثابت کم، پیچیدگی زمانی کمتر و نسبت به نرخ یادگیری زیاد، دقت بیشتری داشته باشیم.

در این پروژه، از روش بیشترین epoch استفاده می‌کنیم. این روش، درون خود روش اول را نیز دارد. روش چهارم نیز برای این دیتاست، اضافه‌کاری محسوب می‌شود.

:۵

```
Test Accuracy: 0.9769999980926514
Test Loss: 0.07319962978363037
Validation Accuracy: 0.9764000177383423
Validation Loss: 0.07930747419595718
Train Accuracy: 0.9902799725532532
Train Loss: 0.03488082066178322
```

:۸

```
Test Accuracy: 0.9799000024795532
Test Loss: 0.06312963366508484
Validation Accuracy: 0.9810000061988831
Validation Loss: 0.06327541172504425
Train Accuracy: 0.9984800219535828
Train Loss: 0.011503975838422775
```

:۱۰

```
Test Accuracy: 0.9810000061988831
Test Loss: 0.06145879998803139
Validation Accuracy: 0.9818000197410583
Validation Loss: 0.06576941162347794
Train Accuracy: 0.9991000294685364
Train Loss: 0.0072038243524730206
```

:۱۵

```
Test Accuracy: 0.9814000129699707
Test Loss: 0.06390372663736343
Validation Accuracy: 0.9836000204086304
Validation Loss: 0.0610683411359787
Train Accuracy: 0.9999600052833557
Train Loss: 0.0017555037047713995
```

در اینجا بنظر می‌رسد که تعداد ۱۰ epoch مناسب باشد. ۱۵ epoch زمان زیادی را مصرف می‌کند و کمتر از ۱۰ هم دقت کمی دارد.

تاثیر activation function

توابع فعال‌سازی موجود در keras عبارتند از : relu ، softmax و sigmoid

Relu معمولا برای لایه‌های پنهان استفاده می‌شود چرا که به خوبی روابط غیر خطی را متوجه می‌شود. اگر خروجی مثبت باشد، همان را نمایش می‌دهد وگرنه، صفر نمایش می‌دهد.

Leaky relu: اجازه می‌دهد که بعضی از مقادیر زیر صفر، نمایش داده شوند.

Softmax: معمولا برای توابع خروجی چند کلاسه استفاده می‌شود.

Sigmoid: معمولا برای توابع خروجی دو کلاسه استفاده می‌شود.

با توجه به این توضیحات، لایه دوم باید از softmax استفاده کند و لایه اول باید یکی از relu وleaky relu را استفاده کند.

Relu:

```
Test Accuracy: 0.980400025844574
Test Loss: 0.06649816036224365
Validation Accuracy: 0.9825999736785889
Validation Loss: 0.0633833035826683
Train Accuracy: 0.9987000226974487
Train Loss: 0.008613154292106628
```

Leaky relu:

```
Test Accuracy: 0.9746999740600586
Test Loss: 0.08215195685625076
Validation Accuracy: 0.977400004863739
Validation Loss: 0.07940288633108139
Train Accuracy: 0.9940000176429749
Train Loss: 0.021806929260492325
```

در اینجا متوجه می‌شویم که معرفی دیتاهای منفی، به درد دیتاست mnist نمی‌خورد. علت این امر این است که ذات mnist با این اتفاق در تداخل است.

تاثیر dropout

یک تکنیک تنظیم‌گری است که به طور معمول در شبکه‌های عصبی استفاده می‌شود . این تکنیک با حذف تصادفی درصد معینی از نورون‌ها در طول آموزش، به جلوگیری از overfitting کمک می‌کند.

انتخاب تصادفی: در طول آموزش، برای هر نمونه آموزشی، زیرمجموعه‌ای تصادفی از نورون‌ها در هر لایه (به جز لایه‌های ورودی و خروجی) با احتمال از پیش تعریف‌شده (مثلاً ۲۰٪، ۵۰٪) حذف می‌شوند.
غیرفعال‌سازی نورون‌ها: نورون‌های انتخاب‌شده برای آن تکرار آموزشی خاص غیرفعال می‌شوند. اتصالات ورودی و خروجی آن‌ها نیز در طول پاس‌های مستقیم و معکوس فرآیند آموزش نادیده گرفته می‌شوند.
یادگیری با شبکه کاهش‌یافت: نورون‌های باقی‌مانده از ساختار شبکه اصلاح‌شده یاد می‌گیرند. از آنجایی که نورون‌های مختلف در هر تکرار حذف می‌شوند، شبکه به طور مؤثر انواع مختلفی از خود را در طول آموزش یاد می‌گیرد.

```
model.add(tf.keras.layers.Dense(1024, activation='relu',
input_shape=(28 * 28,)))
model.add(tf.keras.layers.Dropout(0.1))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
```

بدون dropout:

```
Test Accuracy: 0.980400025844574
Test Loss: 0.06649816036224365
Validation Accuracy: 0.9825999736785889
Validation Loss: 0.0633833035826683
Train Accuracy: 0.9987000226974487
Train Loss: 0.008613154292106628
```

۱۰ درصد:

```
Test Accuracy: 0.9815999865531921
Test Loss: 0.061822447925806046
Validation Accuracy: 0.9810000061988831
Validation Loss: 0.06562712043523788
Train Accuracy: 0.9980999827384949
Train Loss: 0.010288889519870281
```

۲۰ درصد:

```
Test Accuracy: 0.9807000160217285
Test Loss: 0.06399271637201309
Validation Accuracy: 0.9818000197410583
Validation Loss: 0.06364921480417252
Train Accuracy: 0.9977399706840515
Train Loss: 0.011165808886289597
```

۳۰ درصد:

```
Test Accuracy: 0.9800000190734863
Test Loss: 0.06396471709012985
Validation Accuracy: 0.982200026512146
Validation Loss: 0.05994435399770737
Train Accuracy: 0.9976599812507629
Train Loss: 0.012121105566620827
```

۴۰ درصد:

```
Test Accuracy: 0.9814000129699707
Test Loss: 0.059860944747924805
Validation Accuracy: 0.9814000129699707
Validation Loss: 0.06184216961264461
Train Accuracy: 0.9967799782752991
Train Loss: 0.015245678834617138
```

مشاهده می‌شود که بهترین dropout ، برابر با ۱۰ درصد است.

تاثیر batch normalization

این روش به مشکلی به نام "جابجایی همپایه داخلی (internal covariate shift)" رسیدگی می کند و مزایای زیادی را به همراه دارد:

سرعت بخشیدن به آموزش: با استانداردسازی فعال سازی ها، BatchNorm فرآیند آموزش را تثبیت می کند و به شبکه اجازه می‌دهد تا با سرعت بیشتری و با دامنه وسیع‌تری از نرخ یادگیری آموزش ببیند.

کاهش جابجایی همپایه داخلی: استانداردسازی اثر جابجایی همپایه داخلی را کاهش می دهد و یادگیری ویژگی های معنادار را برای لایه های بعدی آسان تر می کند.

بهبود تنظیم BatchNorm :(Regularization) می تواند به عنوان یک تنظیم کننده عمل کند، وابستگی شبکه را به وزن ها و فعال سازی های خاص کاهش دهد و به طور بالقوه به جلوگیری از بیش برازش (overfitting) کمک کند.

بدون batch normalization

```
Test Accuracy: 0.9817000031471252
Test Loss: 0.05697740614414215
Validation Accuracy: 0.9817000031471252
Validation Loss: 0.05857020244002342
Train Accuracy: 0.9965599775314331
Train Loss: 0.01473208237439394
```

پس از batch normalization

```
Test Accuracy: 0.9814000129699707
Test Loss: 0.059853728860616684
Validation Accuracy: 0.9825999736785889
Validation Loss: 0.06220643222332001
Train Accuracy: 0.997219979763031
Train Loss: 0.01094264816492796
```

تفاوت بسیار زیادی بین این دو وجود ندارد ولی با این حال بنظر می‌رسد که بدون batch normalization نیز این مدل به خوبی کار کند. علت این امر می‌تواند این باشد که تا الان پردازش زیادی روی این مدل شده است و با توجه به این‌که دیتاست mnist نسبتا ساده است، ممکن است با اضافه کردن batch normalization به overfitting برسیم.